

Clasificador bayesiano generativo para dígitos MNIST

Probabilidad y Estadística — Proyecto final

1 Problema

El problema consiste en asignar una clase

$$y \in \{0, 1, 2, \dots, 9\}$$

a una imagen

$$x \in \mathbb{R}^{784}$$

(pues cada imagen es de 28×28 píxeles y $28 \cdot 28 = 784$).

Para clasificar, asignamos un puntaje a cada clase y escogemos la clase con mayor puntaje. Esa operación se representa con $\arg \max$:

$$\hat{y} = \arg \max_{c \in \{0, \dots, 9\}} S_c(x).$$

Como queremos un enfoque probabilístico, el puntaje más natural es la probabilidad posterior $P(y = c \mid x)$. Entonces:

$$\hat{y} = \arg \max_{c \in \{0, \dots, 9\}} P(y = c \mid x).$$

2 Metodología

2.1 El teorema de Bayes

La cantidad $P(y = c \mid x)$ no se modela directamente. Usamos Bayes:

$$P(y = c \mid x) = \frac{P(y = c) p(x \mid y = c)}{p(x)}.$$

Bayes cambia la pregunta: en vez de “*dada la imagen, ¿qué tan probable es la clase?*”, pregunta “*si yo supiera que la clase es c , ¿qué tan compatible sería observar una imagen como x ?*”.

Como $p(x)$ no depende de c :

$$\hat{y} = \arg \max_c P(y = c) p(x \mid y = c).$$

Aplicando logaritmo:

$$\hat{y} = \arg \max_c [\log P(y = c) + \log p(x \mid y = c)].$$

2.2 Suposición de modelado

Suponemos que las imágenes de cada clase siguen una distribución normal multivariada:

$$x \mid y = c \sim \mathcal{N}(\mu_c, \Sigma_c).$$

No decimos que y sigue una normal. La clase y es discreta ($y \in \{0, 1, \dots, 9\}$). Lo que modelamos como normal es la imagen x cuando ya sabemos la clase.

La densidad es:

$$p(x \mid y = c) = \frac{1}{(2\pi)^{d/2} |\Sigma_c|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu_c)^\top \Sigma_c^{-1} (x - \mu_c)\right).$$

2.3 Estimación de máxima verosimilitud

Los parámetros μ_c y Σ_c se estiman desde los datos:

$$\hat{P}(y=c) = \frac{N_c}{N}, \quad \hat{\mu}_c = \frac{1}{N_c} \sum_{i: y_i=c} x_i, \quad \hat{\Sigma}_c = \frac{1}{N_c} \sum_{i: y_i=c} (x_i - \hat{\mu}_c)(x_i - \hat{\mu}_c)^\top.$$

Regularizamos $\hat{\Sigma}_c$ añadiendo $\varepsilon \mathbf{I}_d$ con $\varepsilon = 10^{-4}$ para garantizar invertibilidad.

2.4 Regla de clasificación

Sustituyendo la densidad normal y eliminando la constante $\frac{d}{2} \log(2\pi)$:

$$\hat{y} = \arg \max_c \left[\log \hat{P}(y=c) - \frac{1}{2} \log |\hat{\Sigma}_c| - \frac{1}{2} (x - \hat{\mu}_c)^\top \hat{\Sigma}_c^{-1} (x - \hat{\mu}_c) \right]$$

Cada término tiene interpretación:

- $\log \hat{P}(y=c)$: premia clases más frecuentes.
- $-\frac{1}{2} \log |\hat{\Sigma}_c|$: penaliza clases con mucha dispersión.
- $-\frac{1}{2} (x - \hat{\mu}_c)^\top \hat{\Sigma}_c^{-1} (x - \hat{\mu}_c)$: distancia de Mahalanobis entre la imagen y la media de la clase.

La Figura 1 muestra las medias estimadas $\hat{\mu}_c$ de cada clase, que representan el “dígito promedio” de cada clase.




Figure 1: Medias de cada clase $\hat{\mu}_c$ estimadas por máxima verosimilitud.

3 Resultados

El clasificador alcanza una exactitud global del 86,55 % en el conjunto de prueba (10 000 imágenes).

La Figura 2 muestra la varianza por píxel de cada clase (diagonal de $\hat{\Sigma}_c$), y la Figura 3 presenta la matriz de confusión.

La exactitud por clase varía significativamente (Figura 4): dígitos como el 0 y el 1 se clasifican con alta precisión, mientras que el 5 y el 7 presentan mayor tasa de error.



Figure 2: Varianza por píxel de cada clase (diagonal de $\hat{\Sigma}_c$). Las zonas más brillantes indican mayor variabilidad.




Figure 3: Matriz de confusión del clasificador.




Figure 4: Exactitud por clase.

4 Conclusiones

Construimos un clasificador bayesiano generativo. Para cada clase c , modelamos la distribución de las imágenes $x \mid y = c$ mediante una normal multivariada. Estimamos los parámetros de cada clase con los datos de entrenamiento por máxima verosimilitud y luego clasificamos una imagen nueva escogiendo la clase que maximiza la probabilidad posterior $P(y = c \mid x)$.

La interfaz probabilística permite cuantificar la **confianza** en cada predicción mediante las probabilidades posteriores normalizadas. La confianza media es del 99,3% y la mediana del 100,0%, lo que indica que el modelo suele estar muy seguro de sus predicciones correctas; sin embargo, los errores de clasificación tienden a ocurrir en casos con confianza más baja, lo cual es coherente con el marco probabilístico.

Como el denominador de Bayes no depende de la clase, la regla se reduce a maximizar $\log p(x \mid y = c) + \log P(y = c)$, lo que hace la implementación eficiente y sin necesidad de optimización iterativa.